

Decomposizione ai valori singolari di una matrice e applicazioni alla Dynamic Mode Decomposition

Candidato: Federico Maria Riva
Relatore: Professor M. Verani

24 Settembre 2024

1 Singular Value Decomposition - SVD

- Definizione
- Applicazioni

2 Dynamic Mode Decomposition - DMD

- Definizione
- Implementazione
- Applicazione della DMD al modello epidemiologico S.E.I.R.D.

3 Conclusioni e Sviluppi Futuri

4 Bibliografia

Obiettivo

- Presenteremo due strumenti di primaria importanza nell'ambito della matematica applicata: la decomposizione ai valori singolari e la Dynamic Mode Decomposition
- Studieremo come le proprietà della Singular Value Decomposition possono essere applicate alla DMD
- Applicheremo i risultati ottenuti al modello epidemiologico S.E.I.R.D.



Fattorizzazione SVD

Definition 1

Sia $A \in \mathbb{R}^{m \times n}$, oppure $A \in \mathbb{C}^{m \times n}$, e $Rg(A) = r$ allora la decomposizione ai valori singolari di una matrice è definita come:

$$A = U \Sigma V^T$$

Dove:


- $U \in \mathbb{R}^{m \times m}$ è la matrice contenente i *vettori singolari di sinistra* di A , ovvero gli autovalori di AA^T
- $\Sigma \in \mathbb{R}^{m \times n}$ è la matrice contenente i *valori singolari* di A , ovvero le radici quadrate degli autovalori in comune di AA^T e $A^T A$
- $V \in \mathbb{R}^{n \times n}$ è la matrice composta dagli autovettori di $A^T A$ detti anche *vettori singolari di destra*

Definizione

$$A = \begin{bmatrix} | & | & & | \\ \mathbf{u}_1 & \mathbf{u}_2 & \cdots & \mathbf{u}_m \\ | & | & & | \end{bmatrix} \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r & \cdots & 0 \\ 0 & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} | & | & & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \cdots & \mathbf{v}_n \\ | & | & & | \end{bmatrix}^T$$



Definizione

Figura: Illustrazione in $\mathbb{R}^2$

Proposition 1

Fattorizzazione SVD e matrice pseudoinversa

Hp: Sia $A \in \mathbb{R}^{m \times n}$ e $A = U\Sigma V^T$ la sua decomposizione a valori singolari

Ts: La matrice pseudoinversa di A è $A^+ = V\Sigma^+U^T \in \mathbb{R}^{m \times n}$ dove i valori singolari di A^+ sono i reciproci dei valori singolari di A



Proposition 2

Soluzione ai Minimi Quadrati

Hp: Sia $A \in \mathbb{R}^{m \times n}$ una matrice di rango massimo con $m \geq n$, e sia $\mathbf{b} \in \mathbb{R}^m$ e $A = U'\Sigma'V'^\top$ la fattorizzazione SVD ridotta

Ts: Per il sistema di equazioni lineari sovradeterminato $A\mathbf{x} = \mathbf{b}$, la soluzione ai minimi quadrati $\mathbf{x}^$ risolve il seguente problema:*

$$\mathbf{x}^* = \arg \min_{\mathbf{x} \in \mathbb{R}^n} \|A\mathbf{x} - \mathbf{b}\|_2$$

Inoltre, la soluzione è data da:

$$\mathbf{x}^* = (A^\top A)^{-1} A^\top \mathbf{b} = V'\Sigma'^{-1}U'^\top \mathbf{b}.$$



Dynamic Mode Decomposition - DMD

- Dato un insieme di osservazioni spazio-temporali composte da m parametri in n istanti di tempo equidistanti

$$\{\mathbf{x}(t_k), \mathbf{x}(t'_k)\}_{k=1}^n \subset \mathbb{R}^m \text{ e } t'_k = t_k + \Delta t$$

l'obiettivo della DMD è individuare la matrice A che descriva al meglio l'evoluzione del sistema dinamico che ha prodotto i dati

$$\mathbf{x}_{k+1} \simeq A\mathbf{x}_k$$



Definizione

- Le osservazioni possono essere racchiuse in due matrici così costruite

$$X = \begin{bmatrix} | & | & \dots & | \\ \mathbf{x}(t_1) & \mathbf{x}(t_2) & \dots & \mathbf{x}(t_n) \\ | & | & \dots & | \end{bmatrix} \quad X' = \begin{bmatrix} | & | & \dots & | \\ \mathbf{x}(t'_1) & \mathbf{x}(t'_2) & \dots & \mathbf{x}(t'_n) \\ | & | & \dots & | \end{bmatrix}$$

- Una volta ottenuta la matrice A saremo in grado di ricostruire l'evoluzione del sistema a partire dalla condizione iniziale $\mathbf{x}(t_1)$. Il dataset ottenuto avrà la seguente formulazione

$$X \simeq \begin{bmatrix} | & | & \dots & | & \dots & | \\ \mathbf{x}_1 & A\mathbf{x}_1 & \dots & A^i\mathbf{x}_1 & \dots & A^{n-1}\mathbf{x}_1 \\ | & | & \dots & | & \dots & | \end{bmatrix}$$



- Il problema dell'individuazione della matrice A può essere così formulato

$$A = \min_{M \in \mathbb{R}^{m \times m}} \|X' - MX\|_F$$

e tramite la **Proposizione 5** otteniamo la seguente soluzione

$$A = X'X^\top$$



- Poiché nelle applicazioni di comune impiego i parametri osservati sono spesso dell'ordine di 10^6 il calcolo della matrice A risulta essere computazionalmente ingestibile
- Per ovviare a questa problematica ricorriamo alla *Proper Orthogonal Decomposition* (**Teorema 3**) che permette di approssimare al meglio lo Span della matrice A con un minor numero di vettori.



Algoritmo di Tu Ref. [1]

- **Step 1.** Calcoliamo la fattorizzazione SVD ridotta della matrice $X = U'\Sigma'V'^\top$, dove $U' \in \mathbb{R}^{m \times r}$, $\Sigma' \in \mathbb{R}^{r \times r}$, e $V' \in \mathbb{R}^{n \times r}$.
Osserviamo che r può essere sia il rango della matrice che un valore a nostra discrezione minore di $Rg(A)$: ridurre le dimensioni risulta cruciale per grandi matrici X con rango non massimo, alleggerendo il costo computazionale.
Le colonne di U' sono i *Modi* della *Proper Orthogonal Decomposition*.
- **Step 2.** Dal risultato della **Proposizione 5** sappiamo che $A = X'X^+ = X'V'\Sigma'^{-1}U'^\top$. Per evitare una matrice A di dimensioni eccessive proiettiamo A sui *Modi* di U' ottenendo:

$$\bar{A} = U'^\top A U' = U'^\top X' V' \Sigma'^{-1} \in \mathbb{R}^{r \times r}$$



- **Step 3.** Calcoliamo la decomposizione spettrale di $\bar{A}$:

$$\bar{A}W = W\Lambda$$

dove $W \in \mathbb{R}^{r \times r}$ contiene gli autovettori e Λ gli autovalori.

- **Step 4.** I *Modi* $\Phi \in \mathbb{R}^{m \times r}$ vengono ricostruiti come:

$$\Phi = X'V'\Sigma'^{-1}W$$

Abbiamo ricavato gli autovalori di A senza calcolare esplicitamente la matrice di iterazione ottenendo:

$$A\Phi = \Phi\Lambda$$



Ricostruzione del Sistema tramite DMD

- La ricostruzione delle osservazioni si basa su $\mathbf{x}_k = A^{k-1}\mathbf{x}_1$ per $k = 2, \dots, M$. Tuttavia, possiamo sfruttare i Modi della DMD.
- Con $A\Phi = \Phi\Lambda$, possiamo esprimere A^{k-1} come:

$$A^{k-1} = \Phi\Lambda^{k-1}\Phi^+$$

- La soluzione diventa:

$$\mathbf{x}_k = \Phi\Lambda^{k-1}\Phi^+\mathbf{x}_1 = \sum_{j=1}^r \phi_j \lambda_j^{k-1} b_j$$

dove $\mathbf{b} = \Phi^+\mathbf{x}_1 = (W\Lambda)^{-1}\bar{\mathbf{x}}_1$ con $\mathbf{x}_1 = U'\bar{\mathbf{x}}_1$ e λ_j sono gli autovalori.



Modello Epidemiologico S.E.I.R.D

- Il modello S.E.I.R.D. (Suscettibili, Esposti, Infetti, Guariti e Deceduti) è un modello epidemiologico spazio-temporale

$$s, e, i, r, d \in C^{2,1} : \Omega \times [0, T] \rightarrow \mathbb{R}^+, \Omega \subset \mathbb{R}^n.$$

$$\begin{cases} \frac{\partial s(\mathbf{x}, t)}{\partial t} + \beta_i \left(1 - \frac{A_e}{n_{pop}}\right) s(\mathbf{x}, t) i(\mathbf{x}, t) + \beta_e \left(1 - \frac{A_e}{n_{pop}}\right) s(\mathbf{x}, t) e(\mathbf{x}, t) - \nabla \cdot (n_{pop} \nu_s \nabla s(\mathbf{x}, t)) = 0 \\ \frac{\partial e(\mathbf{x}, t)}{\partial t} - \beta_i \left(1 - \frac{A_e}{n_{pop}}\right) s(\mathbf{x}, t) i(\mathbf{x}, t) - \beta_e \left(1 - \frac{A_e}{n_{pop}}\right) s(\mathbf{x}, t) e(\mathbf{x}, t) + (\alpha + \gamma_e) e(\mathbf{x}, t) - \\ + \nabla \cdot (n_{pop} \nu_e \nabla e(\mathbf{x}, t)) = 0 \\ \frac{\partial i(\mathbf{x}, t)}{\partial t} - \alpha e(\mathbf{x}, t) + (\gamma_i + \delta) i(\mathbf{x}, t) - \nabla \cdot (n_{pop} \nu_i \nabla i(\mathbf{x}, t)) = 0 \\ \frac{\partial r(\mathbf{x}, t)}{\partial t} - \gamma_e e(\mathbf{x}, t) - \gamma_i i(\mathbf{x}, t) - \nabla \cdot (n_{pop} \nu_r \nabla r(\mathbf{x}, t)) = 0 \\ \frac{\partial d(\mathbf{x}, t)}{\partial t} - \delta i(\mathbf{x}, t) = 0 \end{cases}$$

- La soluzione numerica del sistema produce un dataset ideale per l'applicazione della DMD composto da un elevato numero di osservazioni in istanti di tempo equidistanti fra loro



Discretizzazione del Modello

- Consideriamo il modello semplificato analizzando un dominio spaziale monodimensionale, $\Omega \subset \mathbb{R}$, e tramite il metodo delle differenze finite all'indietro otteniamo il problema discreto

$$\begin{cases} \frac{S_i^{n+1} - S_i^n}{\tau} - n_{pop} \nu_s \frac{S_{i+1}^{n+1} - 2S_i^{n+1} + S_{i-1}^{n+1}}{h^2} = -\beta_i \left(1 - \frac{A_e}{n_{pop}}\right) S_i^n I_i^n - \beta_e \left(1 - \frac{A_e}{n_{pop}}\right) S_i^n E_i^n =: f_{S_i}^n \\ \frac{E_i^{n+1} - E_i^n}{\tau} - n_{pop} \nu_e \frac{E_{i+1}^{n+1} - 2E_i^{n+1} + E_{i-1}^{n+1}}{h^2} = \beta_i \left(1 - \frac{A_e}{n_{pop}}\right) S_i^n I_i^n + \beta_e \left(1 - \frac{A_e}{n_{pop}}\right) S_i^n E_i^n =: f_{E_i}^n \\ \frac{I_i^{n+1} - I_i^n}{\tau} - n_{pop} \nu_i \frac{I_{i+1}^{n+1} - 2I_i^{n+1} + I_{i-1}^{n+1}}{h^2} = \alpha E_i^n - (\gamma_i + \delta) I_i^n =: f_{I_i}^n \\ \frac{R_i^{n+1} - R_i^n}{\tau} - n_{pop} \nu_r \frac{R_{i+1}^{n+1} - 2R_i^{n+1} + R_{i-1}^{n+1}}{h^2} = \gamma_e E_i^n + \gamma_i I_i^n =: f_{R_i}^n \\ \frac{D_i^{n+1} - D_i^n}{\tau} = \delta I_i^n =: f_{D_i}^n \end{cases}$$



Condizioni Iniziali e agli Estremi

$$\left\{ \begin{array}{ll} s(x, 0) = s_0(x) = e^{-(x+1)^4} + e^{-\frac{(x-0.35)^2}{10^{-2}}} + \frac{1}{8} \left(e^{-\frac{(x-0.62)^4}{10^{-5}}} + e^{-\frac{(x-0.52)^4}{10^{-5}}} + \right. \\ \left. + e^{-\frac{(x-0.42)^4}{10^{-5}}} \right) + \frac{1}{4} e^{-\frac{(x-0.735)^4}{10^{-5}}}; & \frac{\partial s(0,t)}{\partial x} = \phi_a = 0; \quad s(0,t) = \phi_b = 0 \\ e(x, 0) = e_0(x) = \frac{1}{20} e^{-\frac{(x-0.735)^4}{10^{-5}}}; & \frac{\partial e(0,t)}{\partial x} = \phi_a = 0; \quad e(0,t) = \phi_b = 0 \\ i(x, 0) = i_0(x) = 0; & \frac{\partial i(0,t)}{\partial x} = \phi_a = 0; \quad i(0,t) = \phi_b = 0 \\ r(x, 0) = r_0(x) = 0; & \frac{\partial r(0,t)}{\partial x} = \phi_a = 0; \quad r(0,t) = \phi_b = 0 \\ d(x, 0) = d_0(x) = 0; & \frac{\partial d(0,t)}{\partial x} = \phi_a = 0; \quad d(0,t) = \phi_b = 0 \end{array} \right.$$

Formulazione Matriciale

$$\tilde{\mathbf{s}}, \tilde{\mathbf{e}}, \tilde{\mathbf{i}}, \tilde{\mathbf{r}}, \tilde{\mathbf{d}} \in \mathbb{R}^N$$

$$\begin{cases} \tilde{\mathbf{s}}^{n+1} = (I_N + \tau n_{pop} v_s A_h)^{-1} (\tilde{\mathbf{s}}^n + \tau \mathbf{F}_s^n) \\ \tilde{\mathbf{e}}^{n+1} = (I_N + \tau n_{pop} v_e A_h)^{-1} (\tilde{\mathbf{e}}^n + \tau \mathbf{F}_e^n) \\ \tilde{\mathbf{i}}^{n+1} = (I_N + \tau n_{pop} v_i A_h)^{-1} (\tilde{\mathbf{i}}^n + \tau \mathbf{F}_i^n) \\ \tilde{\mathbf{r}}^{n+1} = (I_N + \tau n_{pop} v_r A_h)^{-1} (\tilde{\mathbf{r}}^n + \tau \mathbf{F}_r^n) \\ \tilde{\mathbf{d}}^{n+1} = \tilde{\mathbf{d}}^n + \tau \mathbf{F}_d^n \end{cases} \quad \forall n = 0, \dots, M$$



Applicazione della DMD al modello epidemiologico S.E.I.R.D.

$$A_h = \frac{1}{h^2} \begin{bmatrix} 2 & -2 & 0 & \dots & 0 \\ -1 & 2 & -1 & \dots & \vdots \\ 0 & \ddots & \ddots & \ddots & 0 \\ \vdots & & & & \\ \vdots & \dots & -1 & 2 & -1 \\ 0 & \dots & 0 & -1 & 2 \end{bmatrix} \in \mathbb{R}^{N \times N} \quad \mathbf{F}_S^n = \begin{bmatrix} f_{S0}^n + \frac{2n_{pop} v_s \phi_a}{h} \\ f_{S2}^n \\ \vdots \\ f_{SN}^n + \frac{n_{pop} v_s \phi_b}{h^2} \end{bmatrix} \in \mathbb{R}^N$$

$$\mathbf{F}_E^n = \begin{bmatrix} f_{E0}^n + \frac{2n_{pop} v_e \phi_a}{h} \\ f_{E2}^n \\ \vdots \\ f_{EN}^n + \frac{n_{pop} v_e \phi_b}{h^2} \end{bmatrix} \in \mathbb{R}^N \quad \mathbf{F}_I^n = \begin{bmatrix} f_{I0}^n + \frac{2n_{pop} v_i \phi_a}{h} \\ f_{I2}^n \\ \vdots \\ f_{IN}^n + \frac{n_{pop} v_i \phi_b}{h^2} \end{bmatrix} \in \mathbb{R}^N \quad \mathbf{F}_R^n = \begin{bmatrix} f_{R0}^n + \frac{2n_{pop} v_r \phi_a}{h} \\ f_{R2}^n \\ \vdots \\ f_{RN}^n + \frac{n_{pop} v_r \phi_b}{h^2} \end{bmatrix} \in \mathbb{R}^N$$








Parametri del Modello Epidemiologico

Parametro	Valore
β_i	0.375
β_e	0.375
α	0.09375
γ_e	0.125
γ_i	0.03125
δ	0.0046875
a_e	0
n_{pop}	1
v_s	3.75×10^{-5}
v_e	0.75×10^{-3}
v_i	0.75×10^{-10}
v_r	3.75×10^{-5}



Applicazione della DMD al modello epidemiologico S.E.I.R.D.

Soluzione Numerica





Ricostruzione del Modello S.E.I.R.D

$$X = \begin{bmatrix} | & & | \\ \mathbf{s}_1 & \dots & \mathbf{s}_{M-1} \\ | & & | \\ \mathbf{e}_1 & \dots & \mathbf{e}_{M-1} \\ | & & | \\ \mathbf{i}_1 & \dots & \mathbf{i}_{M-1} \\ | & & | \\ \mathbf{r}_1 & \dots & \mathbf{r}_{M-1} \\ | & & | \\ \mathbf{d}_1 & \dots & \mathbf{d}_{M-1} \\ | & & | \end{bmatrix}$$

$$X' = \begin{bmatrix} | & & | \\ \mathbf{s}_2 & \dots & \mathbf{s}_M \\ | & & | \\ \mathbf{e}_2 & \dots & \mathbf{e}_M \\ | & & | \\ \mathbf{i}_2 & \dots & \mathbf{i}_M \\ | & & | \\ \mathbf{r}_2 & \dots & \mathbf{r}_M \\ | & & | \\ \mathbf{d}_2 & \dots & \mathbf{d}_M \\ | & & | \end{bmatrix}$$

Applicazione della DMD al modello epidemiologico S.E.I.R.D.

Applicazione della DMD al modello epidemiologico S.E.I.R.D.



Conclusioni e Sviluppi Futuri

Conclusioni:

Nel corso di questo lavoro abbiamo messo in evidenza due aspetti principali

- L'importanza dell'uso della decomposizione ai valori singolari per l'implementazione della DMD nel caso di dataset di grandi dimensioni
- La capacità della DMD di ricostruire le dinamiche del modello epidemiologico SEIRD

Sviluppi futuri:

- Estensione del modello SEIRD a più dimensioni spaziali e ricostruzione del dataset bidimensionale tramite DMD



◀ ◻ ▶ ◀ ◻ ▶ ◀ ≡ ▶ ◀ ≡ ▶ ≡



Proposition 3

Hp: Data $M \in \mathbb{R}^{m \times n}$

Ts: $D = M^\top M$ e $S = MM^\top$ sono matrici simmetriche e semi definite positive.

Proposition 4

Hp: Sia $A \in \mathbb{R}^{m \times n}$ con $m \geq n$ e $\{\lambda_i(A^\top A)\}_{i=1}^n$ e $\{\lambda_j(AA^\top)\}_{j=1}^m$ gli autovalori di ciascuna matrice quadrata

Ts: $\{\lambda_i(A^\top A)\}_{i=1}^n \subset \{\lambda_j(AA^\top)\}_{j=1}^m$.

Corollary 2

Hp: Sia $M \in \mathbb{R}^{n \times n}$ con autovalori $\lambda = [\lambda_1, \dots, \lambda_n]$

Ts: Gli autovalori di $M^\top M$ e $MM^\top$ sono gli stessi e valgono $\lambda^2 = [\lambda_1^2, \dots, \lambda_n^2]$



Proposition 5

Hp: Data una matrice $M \in \mathbb{R}^{m \times n}$ con $m \geq n$, $\text{Rg}(M) = r$ e $M = U\Sigma V^\top$ la sua decomposizione SVD

Ts: Allora $M^+ = \arg\min_{B \in \mathbb{R}^{n \times m}} \|MB - I_m\|_F$ dove con M^+ denotiamo la matrice pseudoinversa e grazie alle proprietà della fattorizzazione SVD siamo in grado di trovare la sua formulazione esplicita

$M^+ := V\Sigma^+U^\top$, dove $\Sigma_{i,j}^+ = 0$ se $\Sigma_{i,j} = 0$ e $\Sigma_{i,j}^+ = \frac{1}{\sigma_i}$ se $\Sigma_{i,j} = \sigma_i$.



Theorem 3

Singular Value e Proper Orthogonal Decompositions - Ref. [6]

Hp: Sia $Y \in \mathbb{R}^{m \times n}$ una matrice di rango $d \leq \min m, n$ e sia $Y = U \Sigma V^T$ la sua scomposizione a valori singolari.

Ts: Allora $\forall l \in \{1, \dots, d\}$ la soluzione al seguente problema di ottimizzazione vincolata

$$\max_{\tilde{\mathbf{u}}_1, \dots, \tilde{\mathbf{u}}_l \in \mathbb{R}^m} \sum_{i=1}^l \sum_{j=1}^n |\mathbf{y}_j^T \tilde{\mathbf{u}}_i|^2 \quad s.t. \quad \tilde{\mathbf{u}}_i^T \tilde{\mathbf{u}}_j = \delta_{i,j} \quad 1 \leq i, j \leq l$$

è data dai vettori singolari $\{\mathbf{u}_i\}_{i=1}^l$ ovvero le prime l colonne di U .