

# Decomposizione Matriciale SVD (Singular Value Decomposition)

Federico Riva  
Ingegneria Matematica  
Politecnico di Milano

Relatore: Professor Marco Verani

# Contents

<b>1</b>	<b>Introduzione</b>	<b>3</b>
<b>2</b>	<b>Definizione</b>	<b>3</b>
<b>3</b>	<b>Legame fra la decomposizione SVD ed il Teorema Spettrale</b>	<b>5</b>
<b>4</b>	<b>Interpretazione geometrica</b>	<b>5</b>
<b>5</b>	<b>Dimostrazione della decomposizione SVD e Teorema Eckart-Young</b>	<b>8</b>
5.1	Dimostrazione . . . . .	8
5.2	Norme Matriciali . . . . .	9
<b>6</b>	<b>Algoritmi per il Calcolo</b>	<b>13</b>
<b>7</b>	<b>Applicazioni Teoriche</b>	<b>13</b>
7.1	Pseudoinversa di una Matrice . . . . .	13
7.2	Soluzione ai Minimi Quadrati . . . . .	13
<b>8</b>	<b>Applicazioni Pratiche</b>	<b>13</b>
8.1	PCA - Principal Component Analysis . . . . .	13
8.2	Compressione Immagini . . . . .	13
8.3	DMD - Dynimic Mode Decomposition . . . . .	13
8.3.1	Esempio . . . . .	13

# 1 Introduzione

La decomposizione SVD è una fattorizzazione che consente di rappresentare una matrice come il prodotto di tre matrici ciascuna con caratteristiche specifiche. Le applicazioni di questo metodo possono essere ritrovate in una vasta gamma di campi tra cui l'analisi dei dati, il machine learning e l'elaborazione delle immagini.

## 2 Definizione

Sia  $A \in \mathbb{R}^{m \times n}$ , oppure equivalentemente  $A \in \mathbb{C}^{m \times n}$ , allora la decomposizione SVD della una matrice nel caso  $m > n$  è definita come:

$$A = U \Sigma V^T$$

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} = [\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_m] \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r \\ 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 \end{bmatrix} [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n]^T$$

Mentre per  $m < n$ :

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} = [\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_m] \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma_r & 0 & \cdots & 0 \end{bmatrix} [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n]^T$$

Dove:

- $U \in \mathbb{R}^{m \times m}$  è una matrice ortogonale contenente i vettori singolari sinistri di  $A$ ,
- $\Sigma \in \mathbb{R}^{m \times n}$  è una matrice diagonale contenente i valori singolari di  $A$  ordinati in modo decrescente,
- $V \in \mathbb{R}^{n \times n}$  è una matrice ortogonale contenente i vettori singolari destri di  $A$ .

### Definizione 1. Matrice Ortogonale

Una matrice quadrata  $Q \in \mathbb{R}^{n \times n}$  si dice ortogonale se  $Q^T Q = I$ .

### Definizione 2. Matrice Simmetrica

Una matrice quadrata  $Q \in \mathbb{R}^{n \times n}$  si dice simmetrica se  $Q^T = Q$ .

**Definizione 3. Forma Quadratica**

Si definisce forma quadratica un polinomio di secondo grado in  $n$  variabili  $p : \mathbb{R}^n \rightarrow \mathbb{R}$  t.c.

$$p(x) = p(x_1, \dots, x_n) = \sum_{1 \leq i, j \leq n} a_{ij} x_i x_j = a_{11} x_1^2 + a_{12} x_1 x_2 + \dots + a_{nn} x_n^2 = \mathbf{x}^T A \mathbf{x}$$

dove  $\mathbf{x} = (x_1, \dots, x_n)$  e  $A$  è una matrice simmetrica di dimensione  $n \times n$ .

**Proposizione 1.**

Hp: Data una qualsiasi  $M \in \mathbb{R}^{m \times n}$

Ts:  $D = M^T M$  e  $S = M M^T$  sono matrici simmetriche e definite positive.

*Proof.* 1) Vogliamo dimostrare che  $D = D^T$ . Segue quindi dalle proprietà di trasposizione del prodotto di due matrici:  $D^T = (M^T M)^T = M M^T = D$ . Si dimostra in maniera analoga il risultato per  $S$ .

2) Per dimostrare la semipositività della matrice  $A^T A$  dal momento che è una matrice quadrata possiamo studiare il segno della forma quadratica associata. Se quest'ultima sarà positiva allora lo saranno anche tutti gli autovalori.

$$\forall \mathbf{x} \neq 0 : \mathbf{x} \in \mathbb{R}^n$$

$$\mathbf{x}^T A^T A \mathbf{x} = (A \mathbf{x})^T (A \mathbf{x}) = \|A \mathbf{x}\|^2 \geq 0$$

□

*Osservazione:* Gli autovalori che otterremo dalle due matrici saranno  $\geq 0$  e potremo quindi calcolarne la radice quadrata.

**Proposizione 2.**

Hp: Sia  $A \in \mathbb{R}^{m \times n}$

Ts:  $A^T A$  e  $A A^T$  hanno gli stessi autovalori non nulli.

*Proof.* Ipotizziamo che la coppia autovalor' autovettore  $(\lambda, \mathbf{x})$  sia associata alla matrice  $A^T A$ . Possiamo quindi scrivere

$$A^T A \mathbf{x} = \lambda \mathbf{x}$$

e moltiplicando ambo i membri per  $A$  otteniamo

$$A A^T A \mathbf{x} = \lambda A \mathbf{x}$$

Ma allora definendo  $\mathbf{y} = A \mathbf{x}$  possiamo riscrivere

$$A A^T \mathbf{y} = \lambda \mathbf{y}$$

Il che conclude la dimostrazione poichè prova che  $\lambda$  è un autovalore anche della matrice  $A A^T$  □

**Teorema 1. Teorema Spettrale***Hp: Data  $Q \in \mathbb{R}^{n \times n}$  una matrice simmetrica**Ts: È ortogonalmente diagonalizzabile  $Q = U^{-1}DU = U^T DU$* 

Prendendo in considerazione le **Proposizioni 1, 2** ed il **Teorema 1** possiamo osservare che data una qualsiasi matrice  $A$  è possibile costruire a partire da essa due matrici simmetriche ortogonalmente diagonalizzabili. Possiamo quindi fornire le seguenti definizioni.

**Definizione 4. Vettori Singolari di sinistra**

*I vettori singolari di sinistra di  $A$  sono gli autovettori  $\mathbf{u}_1, \dots, \mathbf{u}_m$  di  $AA^T = U^T D_l U$  e compongono la Matrice Singolare di Sinistra  $U$ .*

**Definizione 5. Vettori Singolari di destra**

*I vettori singolari di destra di  $A$  sono gli autovettori  $\mathbf{v}_1, \dots, \mathbf{v}_n$  di  $A^T A = V^T D_r V$  e compongono la Matrice Singolare di destra  $V$ .*

**Definizione 6. Valori Singolari**

*I valori singolari sono le radici quadrate degli autovalori non nulli di  $A^T A$  e  $A A^T$   
 $\sigma_1 \geq \dots \geq \sigma_{r=\min n,m} \geq 0$ . Inchiederemo con  $r$  il numero di valori singolari che nel caso di assenza di autovalori nulli sarà  $r = \min \{m, n\}$ .*

### 3 Legame fra la decomposizione SVD ed il Teorema Spettrale

Da un punto di vista intuitivo la fattorizzazione SVD può essere considerata come la generalizzazione del concetto di diagonalizzazione di una matrice quadrata; infatti se la seconda può essere applicata solamente a matrici quadrate ( $n \times n$ ) risulta valida per qualsiasi tipo di matrice ( $m \times n$ ) senza limite alcuno sulla sua forma.

Se  $A$  ammette la fattorizzazione SVD allora  $A = U \Sigma V^T$  valgono le seguenti relazioni:

$$A^T A = (U \Sigma V^T)^T U \Sigma V^T = V \Sigma^T U^T U \Sigma V^T = V \Sigma^T \Sigma V^T$$

$$A A^T = U \Sigma V^T (U \Sigma V^T)^T = \dots = U \Sigma \Sigma^T U^T$$

Vale dunque un risultato ancora più specifico della semplice diagonalizzazione di una matrice ovvero il Teorema Spettrale

### 4 Interpretazione geometrica

Data una matrice  $A \in \mathbb{R}^{m \times n}$  consideriamo l'applicazione lineare ad essa associata

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m$$

La fattorizzazione SVD scompone la trasformazione lineare in 3 trasformazioni geometriche rappresentate dalle 3 matrici  $U, V$  e  $\Sigma$  dove le matrici ortonormali rappresentano una

rotazione o una simmetria assiale mentre la matrice  $\Sigma$  è una dilatazione di intensità  $\sigma_i$  lungo la componente  $\mathbf{x}_i$ . Di seguito illustriamo visivamente lo specifico caso  $A \in \mathbb{R}^{2 \times 2}$  nel caso di una circonferenza di raggio unitario che viene mappata in un'ellisse.




Figure 1: Illustrazione in  $\mathbb{R}^2$

Possiamo estendere questo ragionamento ad un caso più generale considerando una sfera di raggio unitario in  $\mathbb{R}^n$  e l'ellissoide ad essa associata da  $A \in \mathbb{R}^{m \times n}$  in  $\mathbb{R}^m$ .

Notiamo che le matrici  $U$  e  $V$  sono unitarie e le colonne di ciascuna formano una base




Figure 2: Mappa da una sfera in  $\mathbb{R}^n$  ad un'ellissoide in  $\mathbb{R}^m$ .

di vettori ortonormali. Inoltre la matrice  $A$  mappa il  $v_i$  elemento della base in nel vettore dilatato  $\sigma_i u_i$ .

Verifichiamolo:

$$A = U\Sigma V^T$$

$$AV = U\Sigma$$

$$[A\mathbf{v}_1 \ A\mathbf{v}_2 \ \dots \ A\mathbf{v}_n] = [U\sigma_1 \ U\sigma_2 \ \dots \ U\sigma_n]$$

Tenendo conto che

$$\sigma_i = [0 \ \dots \ 0 \ \sigma_i \ 0 \ \dots \ 0]$$

Otteniamo

$$\forall i = 1, \dots, n \ A\mathbf{v}_i = \sigma_i \mathbf{u}_i$$

Possiamo quindi scrivere più in generale che:  $A\mathbf{v} = \sigma\mathbf{u}$  e  $A^T\mathbf{u} = \sigma\mathbf{v}$ .

Dal punto di vista degli spazi associati allo *Span* delle colonne di ciascuna matrice se la matrice  $A$  non ha rango massimo,  $\text{Rg}(A) = r < \min\{m, n\}$ , allora sussiste la seguente relazione:

- Le prime  $r$  colonne di  $U$  sono una base dello  $\text{Span}(A)$ ;
- Le ultime  $m - r$  colonne di  $U$  sono una base del  $\text{Ker}(A^T)$ ;
- Le prime  $r$  colonne di  $V$  sono una base dello  $\text{Span}(A^T)$ ;
- Le ultime  $n - r$  colonne di  $V$  sono una base del  $\text{Ker}(A)$

*Osservazione:*  $\text{Span}(A) = \text{Col}(A)$  e quindi  $\text{Span}(A^T) = \text{Col}(A^T) = \text{Row}(A)$ .

La dimostrazione dell'elenco delle proprietà segue dalla **Proposizione 3** unita al **Teorema 1** e alla definizione di decomposizione SVD.

**Teorema 2. Teorema di Nullità più rango**

*Hp:* Sia  $A \in \mathbb{R}^{m \times n}$  con  $\text{Rg}(A) = r$

*Ts:*  $\dim \text{Ker}(A) = n - r$

**Proposizione 3.**

*Hp:*  $\forall A \in \mathbb{R}^{m \times n}$  valgono le seguenti uguaglianze

*Ts:*  $\text{Ker}(A) = \text{Ker}(A^T A)$ ,  $\text{Col}(A^T) = \text{Col}(A^T A)$  e di conseguenza  $\text{Rg}(A) = \text{Rg}(A^T A)$

*Proof.* Osserviamo che

$$\|A\mathbf{x}\|^2 = (A\mathbf{x})^T (A\mathbf{x}) = \mathbf{x}^T A^T A \mathbf{x}$$

Ne segue che, se  $\mathbf{x}$  appartiene al Nucleo di  $A^T A$  allora  $\|A\mathbf{x}\|^2 = 0$  e quindi  $A\mathbf{x} = 0$ , cioè  $\mathbf{x} \in \text{Ker}(A)$ . Viceversa se  $\mathbf{x} \in \text{Ker}(A)$  ripercorrendo la catena di uguaglianze a retroso  $\mathbf{x} \in \text{Ker}(A^T A)$  e per arbitrarietà della scelta del vettore i due nuclei sono uguali. Dall'uguaglianza dei nuclei per il **Teorema 2** segue l'uguaglianza dei ranghi.

$\text{Col}(A^T) = \text{Row}(A)$  è il complemento ortogonale di  $\text{Ker}(A)$ . Ma  $\text{Ker}(A) = \text{Ker}(A^T A)$  il cui complemento ortogonale è  $\text{Row}(A^T A)$ . Quindi  $\text{Col}(A^T) = \text{Row}(A^T A)$  ma per simmetria di  $A^T A$   $\text{Row}(A^T A) = \text{Col}(A^T A) \Rightarrow \text{Col}(A) = \text{Col}(A^T A)$ .  $\square$

## 5 Dimostrazione della decomposizione SVD e Teorema Eckart-Young

### 5.1 Dimostrazione

Data una matrice  $A \in \mathbb{R}^{m \times n}$  poichè  $A^T A \in \mathbb{R}^{n \times n}$  è simmetrica e semidefinita positiva segue dal Teorema Spettrale che  $\exists$  una matrice ortonormale  $V \in \mathbb{R}^{n \times n}$  tale che

$$A^T A = V \bar{D} V^T$$

e a sua volta poichè  $V^{-1} = V^T$

$$V^T A^T A V = \bar{D} = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix}$$

dove  $D \in \mathbb{R}^{\ell \times \ell}$  è una matrice diagonale e positiva di dimensione con  $\ell \leq \min\{m, n\}$  il numero di autovalori non nulli della matrice  $A^T A$ . Osserviamo che per definizione di autovalori e autovettori la  $i$ -esima colonna di  $V$  corrisponde all'  $i$ -esimo autovalore  $\bar{D}_{ii}$ . Di conseguenza possiamo individuare  $V_1 = [\mathbf{v}_1 \dots \mathbf{v}_\ell] \in \mathbb{R}^{n \times \ell}$  e  $V_2 = [\mathbf{v}_{\ell+1} \dots \mathbf{v}_n] \in \mathbb{R}^{n \times n-\ell}$  tali che  $V = [V_1 \ V_2]$  che sono rispettivamente gli autovettori associati ad autovalori non nulli e nulli. Possiamo quindi riscrivere l'equazione come:

$$\begin{bmatrix} V_1^T \\ V_2^T \end{bmatrix} A^T A \begin{bmatrix} V_1 & V_2 \end{bmatrix} = \begin{bmatrix} V_1^T A^T A V_1 & V_1^T A^T A V_2 \\ V_2^T A^T A V_1 & V_2^T A^T A V_2 \end{bmatrix} = \begin{bmatrix} D & 0 \\ 0 & 0 \end{bmatrix}$$

Da cui ricaviamo le seguenti equazioni:

$$V_1^T A^T A V_1 = D \quad \text{e} \quad V_2^T A^T A V_2 = 0$$

Siamo quindi in grado di risolvere la seconda

$$\|AV_2\|_2 = 0 \Rightarrow AV_2 = 0$$

Costruiamo inoltre le seguenti matrici di diverse dimensioni che torneranno utili in seguito:

- $V_1^T V_1 = I_\ell$  dove  $(\ell \times n) \times (n \times \ell) = (\ell \times \ell)$
- $V_2^T V_2 = I_{n-\ell}$  dove  $(n-\ell \times n) \times (n \times n-\ell) = (n-\ell \times n-\ell)$
- $[V_1 V_2][V_1 V_2]^T = V_1 V_1^T + V_2 V_2^T = I_n$  dove

$$(n \times \ell) \times (\ell \times n) = (n \times n) \quad \text{e} \quad (n \times n-\ell) \times (n-\ell \times n) = (n \times n)$$



Definiamo ora la matrice  $U_1$  come:

$$U_1 = AV_1 D^{-\frac{1}{2}} \in \mathbb{R}^{m \times \ell} \{(m \times \ell) = (m \times n) \times (n \times \ell) \times (\ell \times \ell)\}$$

sapendo che  $D^{-\frac{1}{2}}$  è ben definita poiché  $D_{ii} > 0 \forall i = 1, \dots, \ell$ .

Invertendo la relazione e sostituendo  $U_1$ :

$$A = U_1 D^{\frac{1}{2}} V_1^T = AV_1 D^{-\frac{1}{2}} D^{\frac{1}{2}} V_1^T = AV_1 V_1^T$$

e sfruttando  $V_1 V_1^T + V_2 V_2^T = I_n$  e  $AV_2 = 0$  otteniamo:

$$A = A(I - V_2 V_2^T) = A - AV_2 V_2^T = A - 0 = A$$

il che stabilisce la veridicità dalla definizione di  $U_1$  proposta.

Abbiamo quindi quasi dimostrato il risultato completo, non ci resta che verificare che le colonne della matrice  $U_1$  formino una base ortonormale:

$$U_1^T U_1 = D^{-\frac{1}{2}} V_1^T A^T A V_1 D^{-\frac{1}{2}} = D^{-\frac{1}{2}} D D^{-\frac{1}{2}} = I_\ell \in \mathbb{R}^{\ell \times \ell}$$

Possiamo quindi costruire il complemento ortogonale di  $U_1$  ovvero  $U_2 = \text{Span}(\text{Col}(U_1)^\perp) \in \mathbb{R}^{m \times n - \ell}$  in modo che  $U = [U_1 \ U_2] \in \mathbb{R}^{m \times m}$  sia una matrice ortogonale.

Per concludere aggiungiamo un numero opportuno di righe e colonne nulle alla matrice  $D^{\frac{1}{2}} \in \mathbb{R}^{\ell \times \ell}$  in modo da creare:

$$\Sigma = \begin{bmatrix} D^{\frac{1}{2}} & 0 \\ 0 & 0 \\ & 0 \end{bmatrix} \in \mathbb{R}^{m \times n}$$

Allora sfruttando le proprietà del prodotto matriciale fra matrici a blocchi:

$$U \Sigma V^T = [U_1 \ U_2] \begin{bmatrix} D^{\frac{1}{2}} & 0 \\ 0 & 0 \\ & 0 \end{bmatrix} [V_1 \ V_2]^T = [U_1 \ U_2] \begin{bmatrix} D^{\frac{1}{2}} V_1^T \\ 0 \end{bmatrix} = U_1 D^{\frac{1}{2}} V_1^T = A$$

□

## 5.2 Norme Matriciali

Dal momento che  $\mathbb{R}^{m \times n}$  è isomorfo a  $\mathbb{R}^{mn}$  la norma di una matrice è equivalente alla norma di un vettore.

### Definizione 7. Norma

Una funzione  $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$  è detta norma se soddisfa le seguenti proprietà

- $f(A) \geq 0 \forall A \in \mathbb{R}^{m \times n}$  e  $f(A) = 0 \iff A = 0$

- $f(A + B) \leq f(A) + f(B) \quad \forall A, B \in \mathbb{R}^{m \times n}$
- $f(\alpha A) = |\alpha|f(A), \quad \alpha \in \mathbb{R}, A \in \mathbb{R}^{m \times n}$

Useremo quindi la notazione  $\|A\| = f(A)$  per indicare la 'norma della matrice  $A$ '.

Fra le numerose norme esistenti le due più frequenti sono:

**Definizione 8. Norma di Frobenius**

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2}$$

**Definizione 9. Norma  $p$ -esima**

$$\|A\|_p = \sup_{\mathbf{x} \neq 0} \frac{\|A\mathbf{x}\|_p}{\|\mathbf{x}\|_p} = \max_{\|\mathbf{x}\|_p=1} \|A\mathbf{x}\|_p$$

**Definizione 10. Norma  $\infty$**

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}|$$

**Proposizione 4.**

*Hp: Data una matrice ortogonale  $Q \in \mathbb{R}^{n \times n}$*

*Ts:  $\forall \mathbf{x} \in \mathbb{R}^n \quad \|Q\mathbf{x}\| = \|\mathbf{x}\|$*

*Proof.*  $\|Q\mathbf{x}\|^2 = (Q\mathbf{x})^T(Q\mathbf{x}) = \mathbf{x}^T Q^T Q \mathbf{x} = \mathbf{x}^T I \mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2$

□

Enunciamo ora una serie di corollari che seguono dalla dimostrazione della fattorizzazione SVD.

**Corollario 1.**

*Hp: Sia  $U^T A V = \Sigma$  la decomposizione SVD della matrice  $A \in \mathbb{R}^{m \times n}$  con  $m \geq n$ .*

*Ts:  $\forall i = 1, \dots, n \quad A\mathbf{v}_i = \sigma_i \mathbf{u}_i$  e  $A^T \mathbf{u}_i = \sigma_i \mathbf{v}_i$*

*Proof.* Come abbiamo già discusso precedentemente nell'interpretazione geometrica:

$$A = U \Sigma V^T$$

$$A V = U \Sigma$$

$$[A\mathbf{v}_1 \ A\mathbf{v}_2 \ \dots \ A\mathbf{v}_n] = [U\sigma_1 \ U\sigma_2 \ \dots \ U\sigma_n]$$

Tenendo conto che

$$\sigma_i = [0 \ \dots \ 0 \ \sigma_i \ 0 \ \dots \ 0]$$

Otteniamo

$$\forall i = 1, \dots, n \quad A \mathbf{v}_i = \sigma_i \mathbf{u}_i$$

Analogamente si dimostra il risultato per  $A^T \mathbf{u}_i = \sigma_i \mathbf{v}_i$

□

**Corollario 2.**

*Hp:* Sia  $A \in \mathbb{R}^{m \times n}$  con  $m \geq n$

*Ts:*  $\|A\|_2 = \sigma_1$  e  $\|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}$

*Proof.* 1)

$$\|A\|_2 = \max_{\|\mathbf{x}\|_2=1} \|A\mathbf{x}\|_2 = \max_{\|\mathbf{x}\|_2=1} \|U\Sigma V^T \mathbf{x}\|_2$$

Dalla **Proposizione 4** sappiamo che le due matrici ortogonali  $U$  e  $V$  non modificano la norma. Possiamo quindi riscrivere l'uguaglianza come

$$\max_{\|\mathbf{x}\|_2=1} \|\Sigma \mathbf{x}\|_2$$

cioè

$$\max_{\|\mathbf{x}\|_2=1} \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \sigma_r \\ 0 & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

e poichè  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$  otteniamo il massimo per  $\mathbf{x} = [1 \ 0 \ \dots \ 0]^T$  ovvero  $\|A\|_2 = \sigma_1$

2)

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |(U\Sigma V^T)_{ij}|^2}$$

scrivendo il prodotto matriciale elemento per elemento otteniamo che

$$(U\Sigma V^T)_{ij} = \sum_{k=1}^r U_{ik} \Sigma_{kk} (V^T)_{kj} = \sum_{k=1}^r U_{ik} \Sigma_{kk} V_{jk}$$

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n \sum_{k=1}^r U_{ik} \Sigma_{kk} V_{jk}}$$

Tuttavia per costruzione della matrice  $\Sigma$

$\Sigma_{kk} = \sigma_k \geq 0 \ \forall k = 1, \dots, r$  con  $r \leq n = \min\{m, n\}$  e  $\Sigma_{ij} = 0 \ \forall i = 1, \dots, m$  e  $\forall j = 1, \dots, n$

Otteniamo la tesi

$$\|A\|_F = \sqrt{\sigma_1^2 + \dots + \sigma_r^2}$$

□

**Corollario 3.**

*Hp:*

*Ts:*

*Proof.*

□

**Corollario 4.**

*Hp:*

*Ts:*

*Proof.*

□

**Teorema 3. Teorema di Eckart-Young**

*Hp:* Sia  $A$  una matrice  $m \times n$  di rango  $r$ , e sia  $k \in \mathbb{N}$  tale che  $1 \leq k \leq r$ .

*Ts:*  $\forall$  matrice  $B$  di rango  $k$ , la soluzione del problema di minimo quadrato:

$$\min_{\text{rank}(X)=k} \|A - X\|_F^2$$

è data dalla matrice  $X$  data dalla decomposizione ai valori singolari troncata di  $A$ , ovvero:

$$X = \sum_{i=1}^k \sigma_i u_i v_i^T$$

dove  $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0$  sono i valori singolari di  $A$ , e  $u_i$  e  $v_i$  sono rispettivamente la  $i$ -esima colonna di  $U$  e la  $i$ -esima colonna di  $V$  nella decomposizione ai valori singolari di  $A$ , ovvero  $A = U\Sigma V^T$ , con  $U$  una matrice  $m \times r$ ,  $V$  una matrice  $n \times r$ , e  $\Sigma$  una matrice diagonale  $r \times r$  contenente i valori singolari di  $A$  sulla diagonale.

## 6 Algoritmi per il Calcolo

## 7 Applicazioni Teoriche

### 7.1 Pseudoinversa di una Matrice

### 7.2 Soluzione ai Minimi Quadrati

## 8 Applicazioni Pratiche

### 8.1 PCA - Principal Component Analysis

### 8.2 Compressione Immagini

### 8.3 DMD - Dynamic Mode Decomposition

#### 8.3.1 Esempio